MVIG 真机实践成果展示：随机位置多积木入杯

朱荟霖 HUILIN ZHU

2025 JOHN class

1 任务介绍

本项目以实验室提供的 I2RT 双臂机器人为平台，研究桌面随机布局下的多积木入杯任务：机器人从工作起始姿态出发，依次抓取积木并放入目标杯，完成后将双臂恢复至工作起始姿态。其中积木位置、颜色、姿态与杯子位置、颜色不固定，但保障在机械臂工作区。

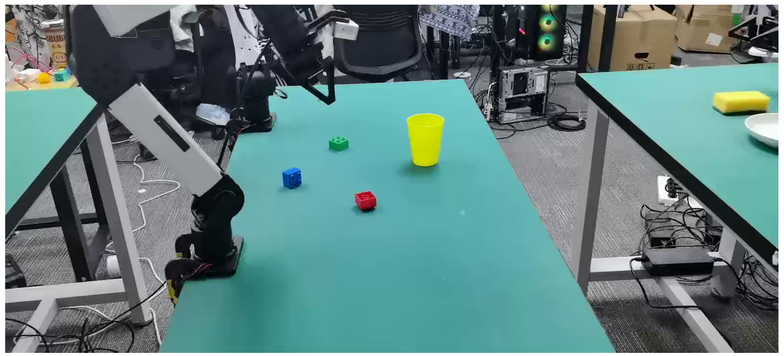


Figure 1. 某次起始桌面：绿色正放、蓝色侧放、红色倒放；黄色杯子为放置目标。

任务的难点主要是三点。一是位置、颜色、姿态变化对模型泛化性的挑战，二是积木数量多带来的长任务问题，三是缺少头部摄像头对全局位置感知的困难。

2 数据采集

数据主要由手动操纵左右 leader，引导两只 follower 完成“抓取、入杯、复位”的完整示范获取。双腕 D405 相机同步参与记录，各设备数据及时间戳以 NEDF3 / MCAP 保存，每次完整示范构成一个 episode。设备各自采样，记录后进行时间对齐。

每帧训练观测包含左右腕 RGB 图像，以及 follower 的 14 维实测状态；维度顺序为左臂六关节、左夹爪、右臂六关节、右夹爪。动作由 leader 记录按照实际遥操作的方向和偏置映射为 follower 目标，关节单位为 rad，夹爪开度为 $[0, 1]$。

Table 1. 单个 episode 对齐后的训练数据构成

数据项	维度 / 格式	说明
视觉观测	双路 RGB 图像	左、右腕 D405 图像；ACT 使用 480×640，$\pi_{0.5}$ 使用 224×224（高 × 宽）。
机器人状态	$T \times 14$	follower 实测状态，包含双臂共 12 个关节位置与 2 个夹爪开度。
动作目标	$T \times 14$	leader 记录经遥操作映射重建的 follower 目标，包含关节位置与夹爪开度。
时间信息	T 个时间点	按 30 Hz 时间网格对齐，保留采样时间与逐帧来源，用于检查图像、状态和动作的对应关系。
片段边界	独立 episode	保存一次完整示范；动作块不跨片段，训练时分别处理片段末尾的不足长度。

数据采集的优化主要针对“缺少头部摄像头问题”：示范时主要让左臂充当观察者，右臂充当执行者进行抓取。

数据处理的优化主要针对“数据正确性”：核对左右臂、相机身份与关节映射，避免角色交换和符号错误；以 30 Hz 时间网格选取时效合格的最近过去样本，对齐图像、状态和动作。检查黑帧、卡帧、缺流、漏放、失败等不合格示范，完整保留任务与复位阶段。数据随后分别转换为 ACT 使用的 HDF5 和 $\pi_{0.5}$ 使用的 LeRobot 格式。

3 模型选择

1. ACT: Action Chunking with Transformers

ACT 使用视觉编码器与 Transformer，根据当前图像和机器人状态一次预测未来动作块，并通过条件变分自编码训练建模示范动作 [1]。本项目沿用官方主体网络，使用预训练 ResNet18 视觉骨干和两路 480×640 腕部图像，学习 100 步、每步 14 维的绝对关节与夹爪目标。实际训练使用 60 条已筛选示范，其中 50 条训练、10 条验证，共训练 35000 步。

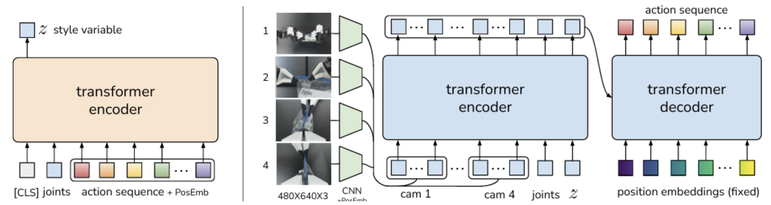


Figure 2. ACT 模型结构示意图。

ACT 的优势是推理开销较低、动作块便于连续执行，适合学习重复且精确的抓放技能。局限在于视觉与动作关联主要依赖任务示范；布局覆盖不足时，模型可能偏向熟悉的空间位置和运动轨迹，而未能正确响应新的目标位置。动作平稳不等于抓取目标正确。

2. $\pi_{0.5}$: a Vision-Language-Action Model

$\pi_{0.5}$ 是预训练视觉语言动作模型，以图像、语言任务和机器人状态为条件，通过流匹配生成动作 [2, 3]。本项目基于 OpenPI 基础权重进行全量微调。实际训练使用 60 条已筛选示范，全部参与训练，不设置验证集，预热 1000 步，共微调 20000 步。训练时关节目标表示为相对当前状态的差值，夹爪保持绝对开度，经分位数归一化后补至 32 维；执行前还原为 14 维绝对目标。

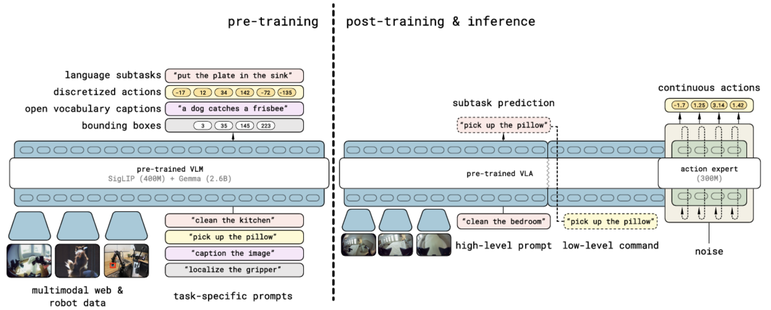


Figure 3. $\pi_{0.5}$ 模型结构示意图。

预训练视觉语义知识为识别不同姿态的积木和适应布局变化提供了基础，更适合探索任务泛化。但模型计算开销更高，通用先验也不能直接保证本机夹持与释放精度；精细操作仍依赖本体适配、局部视觉反馈和高质量示范。

4 部署管线

部署层面做出的优化针对推理延迟与动作块交接，模型异步生成预测，执行端按观测时间戳定位当前应执行的动作，不堆积补算请求，也不重播过期动作。ACT 对覆盖同一时刻的重叠预测进行时间集成；$\pi_{0.5}$ 使用最新有效且已对齐的动作块。

控制端从实际反馈初始化指令，以独立设备循环连续限速推进，避免将远端预测目标一次下发；同时检查数值、关节范围、反馈时效及实际指令跟踪误差。

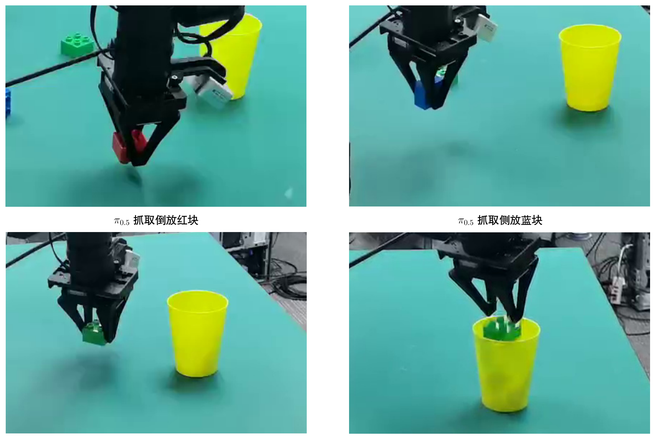
5 结果分析



ACT：两块积木之间空抓　ACT：接触杯子并使其倾斜　ACT：杯子倒下

Figure 4. ACT 失败片段

现场观察中，ACT 运动较快、轨迹较稳定，但随机布局下的目标定位出现偏差：夹爪在两块积木之间空抓，随后碰倒杯子。可能原因是示范对空间变化的覆盖不足，策略过度依赖熟悉的动作轨迹；另一种可能是示范中的目标选择与抓取顺序不一致，产生多峰分布问题。



$\pi_{0.5}$ 抓取倒放红块　$\pi_{0.5}$ 抓取侧放蓝块

$\pi_{0.5}$ 抓取正放绿块　$\pi_{0.5}$ 抓取积木入杯

Figure 5. $\pi_{0.5}$ 抓取三种初始姿态的积木并完成最后释放；初始布局见图 1。

$\pi_{0.5}$ 在该段演示中能够针对不同摆放姿态抓取并入杯，表现出更好的目标适应性，但执行较慢，局部对位与释放仍不够利落。

未来可探索“慢系统理解目标、快系统精细执行”的双系统架构：由 VLA 低频识别目标积木、杯口与任务阶段，输出目标区域、关键点或子目标；由高频的目标条件 ACT 结合局部高分辨率图像和关节反馈，执行接近、夹持与放置。事实上，我并未严格统计成功率数值，有关成功率的表述为大致的定性分析。

6 总结

本项目的主要贡献是在无头部相机条件下设计解决泛化性需求高的全局长任务，完成双腕示范数据采集到两类策略训练与真机执行的适配，并通过实际任务分析提出分层双系统的改进方向。

参考文献

[1] Tony Z. Zhao, Vikash Kumar, Sergey Levine, and Chelsea Finn. Learning fine-grained bimanual manipulation with low-cost hardware. *arXiv preprint arXiv:2304.13705*, 2023. URL https://arxiv.org/abs/2304.13705.

[2] Physical Intelligence, Kevin Black, Noah Brown, et al. $\pi_{0.5}$: a vision-language-action model with open-world generalization. *arXiv preprint arXiv:2504.16054*, 2025. URL https://arxiv.org/abs/2504.16054.

[3] Physical Intelligence. OpenPI: Official policy implementation. https://github.com/Physical-Intelligence/openpi. Accessed 2026-11-05.